

单细胞高维向量数据的近似最近邻（ANN）检索系统设计报告

2312147 彭振皓

摘要

本报告围绕“面向单细胞高维向量数据的近似最近邻（ANN）检索系统”进行软件设计。系统面向大规模单细胞测序数据，将每个细胞表示为高维向量，提供数据导入与预处理、精确检索、近似检索、多索引结构管理、查询结果展示以及性能评测等功能。报告按照软件工程设计文档的基本结构，说明系统背景、功能需求、总体架构、关键模块、数据库与接口设计，使用亿图图示给出用例图、类图、顺序图、活动图、状态图、组件图和部署图。

设计目标是在保证检索质量的前提下提高大规模高维向量检索效率，使用户能够通过 Web 页面输入查询细胞或查询向量，设置 top-k、索引类型和距离度量方式等参数，并直观查看相似样本、查询耗时、索引状态和评测指标。

UML 图设计与说明

用例图




图 1：单细胞高维向量 ANN 检索系统用例图

本用例图描述了“单细胞高维向量 ANN 检索系统”的功能边界、系统参与者（Actors）以及各项功能（Use Cases）之间的交互与依赖关系。

系统参与者（Actors）

系统包含两类主要参与者：

1. **普通用户**：系统的核心使用者，通常为从事单细胞数据分析的科研人员。他们需要完成从数据导入、索引构建到查询检索和结果分析的全套业务流程。
2. **管理员**：负责系统运行维护和用户权限管理的人员。

参与者与核心用例的关系

- **普通用户权限**：普通用户与系统左侧的大部分用例存在直接交互关系。他们可以执行的操作包括：**注册/登录**、**导入单细胞数据**、**浏览数据集**、**构建索引**、**保存/加载索引**、**设置检索参数**、**精确检索**、**近似检索**、**查看 Top-k 结果**以及**查看评测指标**。
- **管理员权限**：管理员拥有部分基础权限和专属管理权限。他们同样可以进行**注册/登录**和**导入单细胞数据**，此外还拥有特有的**系统用户管理**权限，用于维护系统的用户状态和安全。

用例间的依赖关系

图中使用虚线箭头清晰地标明了用例之间的“包含（<>）”和“扩展（<>）”关系，揭示了系统内部的业务流转逻辑：

1. 包含关系（<>）—— 表示必须执行的前置或共用步骤：

- **数据预处理**：**导入单细胞数据** 和 **浏览数据集** 这两个用例都包含（<>）了 **数据预处理** 用例。这意味着在用户导入新数据或浏览现有数据集时，系统必然会在底层触发格式转换、清洗或向量化等预处理动作。
- **设置检索参数**：**精确检索** 和 **近似检索** 都包含（<>）了 **设置检索参数** 用例。这表明无论用户发起何种类型的搜索，设定好查询条件（如目标细胞ID、Top-k数量等）都是执行检索的必经步骤。

2. 扩展关系（<>）—— 表示在特定条件下的可选附加步骤：

- **保存/加载索引 扩展 构建索引**：**保存/加载索引** 是指向 **构建索引** 的扩展操作。这意味着用户在完成“构建索引”的核心任务后，可以选择性地触发保存或加载动作，以便后续快速复用，这并非每次构建都强制要求的操作。
- **查看结果与指标 扩展 近似检索**：**查看 Top-k 结果** 和 **查看评测指标** 均指向 **近似检索**，属于其扩展用例。这意味着当一次“近似检索”执行完毕后，用户可以根据需要，选择进入可视化界面查看排名前 k 的相似细胞结果，或者查看本次检索的性能评测指标（如耗时、召回率等）。

类图




图 2：单细胞高维向量 ANN 检索系统类图

本类图展示了“单细胞高维向量 ANN 检索系统”的静态物理结构，详细定义了系统中的核心类、类的属性与方法，以及各个类之间的交互与依赖关系。系统采用模块化设计，主要分为用户管理、数据管理、核心检索、结果评估与可视化显示等几个核心部分。

核心类定义及功能描述

1. 用户与权限模块

- **User (普通用户类)**：系统的基础用户类。包含属性如 `userId` (用户ID)、`username` (用户名)、`password` (密码) 和 `role` (角色)。提供基础的用户操作方法，如 `login()` (登录)、`logout()` (登出) 和 `register()` (注册)。
- **Admin (管理员类)**：继承自 `User` 类。除了拥有普通用户的所有属性和方法外，还提供管理员专属的方法 `manageUsers()` (管理用户)，用于维护系统的用户状态。

2. 数据管理模块

- **DatasetManager (数据集管理类)**：负责整个单细胞数据集的管理和调度。包含属性 `datasetName` (数据集名称) 和 `cellCount` (细胞总数)。提供 `importData()` (导入数据)、`validateData()` (验证数据格式)、`preprocessData()` (数据预处理) 和 `getCellVector()` (获取指定细胞向量) 等核心数据操作方法。
- **CellVector (细胞向量类)**：表示单个细胞的实体数据。包含 `cellId` (细胞唯一标识)、`vector` (高维特征向量数组) 和 `metadata` (元数据字典，如细胞类型、组织来源等)。提供 `normalize()` (向量归一化) 和 `getDimension()` (获取向量维度) 等自身数据处理方法。

3. 核心检索与索引模块

- **QueryEngine (查询检索引擎类)**：执行相似性搜索的核心计算类。包含 `metric` (距离度量方式，如 L2) 和 `topK` (返回的近邻数量) 属性。提供 `exactSearch()` (精确检索计算)、`annSearch()` (近似最近邻检索计算) 以及 `setParams()` (设置检索参数) 方法。
- **IndexManager (索引管理类)**：负责 ANN 底层索引的生命周期管理。包含 `indexType` (索引结构类型，如 Faiss) 和 `indexStatus` (索引状态)。提供 `buildIndex()` (构建索引)、

`saveIndex()` (保存索引到磁盘)、`loadIndex()` (加载索引到内存) 和 `deleteIndex()` (删除索引) 方法。

4. 结果与评测模块

- **SearchResult (检索结果类)**：封装单次查询的结果集。包含 `queryId` (查询细胞ID)、`resultList` (相似细胞列表) 和 `latency` (查询延迟时间)。提供 `sortResults()` (结果排序) 和 `formatResults()` (格式化输出结果) 方法。
- **Evaluator (评测指标类)**：用于对 ANN 算法的性能进行量化评估。包含 `recall` (召回率)、`precision` (精确率) 和 `qps` (每秒查询率) 等性能属性。提供 `evaluateRecall()`、`evaluateLatency()` 和 `generateReport()` (生成评测报告) 方法。

5. 系统控制与视图模块

- **SystemController (系统控制器类)**：作为整个系统的主控中心，负责接收前端请求并调度各子模块。提供 `handleRequest()` (处理请求) 和 `coordinateModules()` (协调模块间工作) 方法。
- **VisualizationView (可视化视图类)**：负责前端的界面展示与渲染。包含 `pageTitle` (页面标题) 属性，提供 `showDataset()` (展示数据集概览)、`showResults()` (展示检索结果图表/表格) 和 `showMetrics()` (展示性能评测图表) 方法。

类之间的关系说明

图中的连线和箭头清晰地表达了各个对象之间的协作模式：

1. 继承关系 (泛化)：

- `Admin` 类指向 `User` 类的空心三角箭头表示**继承关系**，管理员是用户的特殊形态，继承了其基础属性和行为。

2. 聚合关系 (整体与部分)：

- `DatasetManager` 与 `CellVector` 之间使用空心菱形连接，表示**聚合关系**。一个数据集 (整体) 包含了 1 到多 (*) 个细胞向量 (部分)。即使数据集对象被销毁，原始的细胞向量文件或数据可能依然独立存在。

3. 依赖关系 (虚线箭头)：

- **主控调度**：`SystemController` 通过虚线箭头 (依赖) 指向 `QueryEngine`、`SearchResult`、`Evaluator` 和 `VisualizationView`，表明控制器在执行业务逻辑时，需要实例化或调用这些功能类的方法。
- **对象创建**：`QueryEngine` 指向 `SearchResult` 并标注“创建”，表明引擎完成搜索动作后会实例化一个结果对象返回。
- **数据传递**：`Evaluator` 依赖于 `SearchResult`，因为评测计算必须基于检索结果进行；`VisualizationView` 依赖于 `SearchResult` 和 `Evaluator`，用于在界面上“显示”这两种类型的数据。

4. 关联关系 (使用 / 引用)：

- `QueryEngine` 和 `IndexManager` 都带有指向 `DatasetManager` 的实线箭头 (标注“使用”)，这表明检索引擎和索引构建器在工作时，都需要频繁访问数据集管理器来获取底层的高维向量数据。

顺序图




图 3：单细胞高维向量 ANN 检索系统顺序图

本顺序图展示了系统处理一次完整的“近似最近邻（ANN）检索”请求的动态交互过程。图中按时间顺序（从上至下）详细描述了用户发起查询后，系统中各个对象之间消息传递、方法调用及响应的完整生命周期。

参与交互的对象（生命线）

本次流程涉及以下参与者和系统对象：

- **用户 (Actor)**: 系统的使用者，发起检索请求。
- **Web界面 (UI Component)**: 负责接收用户输入和展示最终结果的前端组件。
- **SystemController (系统控制器)**: 后端业务调度的核心枢纽。
- **QueryEngine (检索引擎)**: 负责执行具体 ANN 算法计算的核心模块。
- **IndexManager (索引管理器)**: 负责维护和加载底层高维向量索引结构。
- **DatasetManager (数据管理器)**: 负责提供底层原始数据集和候选向量。
- **SearchResult (结果实体)**: 封装单词检索的匹配列表和耗时等信息的对象。
- **VisualizationView (可视化视图)**: 负责将结果数据转换为图表或前端可读渲染数据的组件。

详细交互步骤

阶段 1：请求发起与参数初始化

1. **输入参数**: 用户在 **Web界面** 上输入查询条件，包括目标细胞ID（或查询向量）以及设定返回结果的数量（top-k参数）。
2. **提交请求**: Web界面将这些参数打包，通过 `submitQuery(query, params)` 消息发送给后端 **SystemController**。
3. **引擎初始化**: SystemController 接收到请求后，首先调用 **QueryEngine** 的 `setParams(metric, topK, indexType)` 方法，初始化本次查询的距离度量方式、top-k 大小及指定的索引类型。
4. **触发检索**: 参数设置完毕后，SystemController 向 QueryEngine 发送 `annSearch(query)` 消息，正式启动检索计算流程。

阶段 2：索引校验与加载 (Alt 组合片段) 检索引擎在执行计算前，必须检查底层索引的状态。此阶段包含一个条件分支 (alt 片段)：

- **分支 [索引存在]:**

- 1. 如果系统检测到指定的索引已建立，QueryEngine 调用 **IndexManager** 的 `loadIndex()/checkIndex()` 方法加载或校验内存中的索引。
- 1. IndexManager 完成准备后，返回 `indexReady` 状态。

- **分支 [索引不存在]:**

- 5a. 如果是首次查询或索引已失效，QueryEngine 会通知 IndexManager 调用 `buildIndex()` 方法即时构建新的索引。
- 5b. 构建完成后，IndexManager 返回 `indexReady` 状态。

阶段 3：执行近似最近邻计算 7. **获取候选集**：索引准备就绪后，QueryEngine 向 **DatasetManager** 发出 `getCandidateVectors()` 请求，以获取需要在其中进行搜索的底层向量数据池。8. **数据返回**：DatasetManager 将底层的候选向量集 (candidate set) 返回给 QueryEngine。9. **核心计算**：QueryEngine 触发内部自调用 `compute approximate nearest neighbors`，利用加载的索引和底层数据执行核心的 ANN 距离计算算法。

阶段 4：结果封装与可视化渲染 10. **创建结果对象**：计算完成后，QueryEngine 实例化一个 **SearchResult** 对象，通过 `create(resultList, latency)` 将排名前 k 的相似细胞列表和本次查询的延迟耗时封装进去。11. **返回控制器**：QueryEngine 将生成的 `result object` 返回给主控 **SystemController**。12. **请求渲染**：SystemController 将获取到的结果对象传递给 **VisualizationView**，调用其 `showResults(result)` 方法。13. **生成视图数据**：VisualizationView 处理原始数据，生成用于前端展示的图表坐标或表格结构 (`render top-k results and metrics`)，并将渲染后的视图数据返回给 SystemController。14. **前端展示**：SystemController 将最终整合的响应数据发送给 **Web界面**，由 Web界面向**用户**展示直观的检索结果和可视化图形。整个业务交互流程结束。

协作图




图 4：单细胞高维向量 ANN 检索系统协作图

本协作图重点展示了在执行一次“近似最近邻 (ANN) 检索”任务时，系统内部各个核心对象 (模块) 之间的空间组织结构以及消息传递的先后顺序。与顺序图强调时间轴不同，协作图更直观地体现了“查询检索模块”作为本次交互调度的中心节点地位。

参与交互的系统节点（对象）

图中包含一个外部参与者和五个内部核心模块节点：

1. **用户 (Actor)**：检索请求的发起者和最终结果的接收者。
2. **Web界面**：系统的表现层，负责与用户进行交互，收集参数并展示结果。
3. **查询检索模块**：本次协作的**中心控制节点**，负责接收前端请求，并协调其他底层模块完成检索任务。
4. **索引管理模块**：负责底层 ANN 索引实例的加载、校验和生命周期管理。
5. **索引结构 (ANN索引)**：实际存在于内存或磁盘中的物理索引数据结构（如 Faiss 索引库），负责执行底层的快速相似度匹配。
6. **数据管理模块 (向量数据)**：负责管理和提供原始的单细胞高维向量数据及相关的细胞元数据。

交互流程与消息序列

围绕“查询检索模块”，整个检索任务通过 10 个按序号排列的消息依次协同完成：

- **阶段一：请求发起 (步骤 1-2)**
 - **1: 输入查询条件** —— 用户在 **Web界面** 上输入目标查询细胞的 ID（或自定义向量）以及设定所需的 Top-k 近邻数量等过滤参数。
 - **2: 提交查询请求** —— **Web界面** 将收集到的参数打包，向后端的中心枢纽 **查询检索模块** 发送正式的检索请求。
- **阶段二：获取索引环境 (步骤 3-4)**
 - **3: 获取索引 (类型/参数)** —— **查询检索模块** 收到请求后，首先向 **索引管理模块** 发送消息，请求获取当前检索所需的指定类型和参数的索引实例。
 - **4: 返回索引实例** —— **索引管理模块** 完成内部的加载或校验后，将可用的索引实例句柄返回给 **查询检索模块**。
- **阶段三：执行核心计算 (步骤 5-6)**
 - **5: 执行近似检索 (查询向量, top-k)** —— 环境准备就绪，**查询检索模块** 调用底层的 **索引结构 (ANN索引)**，传入目标查询向量和设定的 top-k 数量，触发核心的 ANN 距离计算算法。
 - **6: 返回候选结果** —— **索引结构** 完成高维空间的距离测算后，向 **查询检索模块** 返回一组最相似的候选细胞的内部标识 (IDs) 和对应的距离评分。
- **阶段四：数据补全 (步骤 7-8)**
 - **7: 获取向量数据 (必要时)** —— 由于索引结构通常只返回细胞的 ID，**查询检索模块** 需要向 **数据管理模块** 发起数据获取请求，传入这些候选 ID，以获取完整的原始高维向量数据或详细的细胞元数据（如细胞类型、组织来源等）。
 - **8: 返回向量数据** —— **数据管理模块** 从底层存储中提取对应的详细数据，并返回给 **查询检索模块** 进行最终的结果拼接和封装。
- **阶段五：结果响应 (步骤 9-10)**
 - **9: 返回结果** —— **查询检索模块** 将封装好的完整 Top-k 检索结果对象（包含细胞详细信息、距离得分等）发回给前端的 **Web界面**。
 - **10: 展示查询结果** —— 最终，**Web界面** 将接收到的数据渲染为可视化的图表（如 UMAP 降维图）或数据表格，直观地呈现给 **用户**。整个协作交互过程闭环结束。

活动图




图 5：单细胞高维向量 ANN 检索系统活动图

本活动图详细描述了从用户发起检索请求到最终结果展示及性能评测的完整业务逻辑流。图表清晰地展示了系统在处理检索任务时的自动化判断机制和核心计算步骤。

流程初始化阶段

- 用户进入系统：** 流程的起点。用户通过 Web 界面访问单细胞检索模块。
- 输入查询信息：** 用户选择或输入待查询的单细胞 ID，或者直接上传自定义的高维基因表达向量。
- 设置检索参数：** 用户配置本次任务的关键参数，包括索引结构类型（如 Faiss-IVF, HNSW 等）、距离度量方式（如 L2 距离或余弦相似度）以及期望返回的近邻数量（Top-k）。

索引状态判定与构建逻辑（核心判断点）

系统在执行检索前，会进入一个关键的决策分支（Decision Point）：“索引是否已构建？”

- **若“否”（未构建）：** 系统将触发自动构建流程。
 - 首先执行**导入数据**操作，读取原始 H5AD 或表达矩阵文件。
 - 随后进入**数据预处理**阶段，完成数据归一化和向量化组织。
 - 最后执行**构建索引**，并在完成后将控制权移交给检索执行步骤。
- **若“是”（已存在）：** 系统跳过构建步骤，直接利用内存中已加载的索引结构进入检索阶段，从而显著提升响应速度。

核心检索与结果处理阶段

- 1. 执行近似检索： 调用底层算法库，在索引空间内利用 ANN 技术快速定位候选区域。
- 2. 相似度计算： 系统在候选区域内计算查询向量与目标样本间的精确距离/相似度。
- 3. 结果处理：
 - 结果排序： 按照距离由近到远（或相似度由高到低）进行排列。
 - Top-k 截断： 根据用户设定的参数提取排名最靠前的结果集。
- 4. 展示检索结果与耗时： 在 Web 页面渲染 Top-k 细胞详情列表，并同步显示本次检索的响应延迟。

性能评测可选流程（二阶段判断点）

在展示基本结果后，系统提供了一个可选的性能深度分析分支：“是否展示性能评测？”

- 若选择“是”： 系统将触发后台评测引擎，自动计算 Recall（召回率）、Precision（精确率）、Latency（延迟）和 QPS（每秒查询率）*等指标。计算完成后，在界面上专门*展示评测指标图表。
- 若选择“否”： 流程直接结束。

流程结束

- 终点： 系统完成所有数据反馈，用户查看完毕，单次检索业务流程闭环

状态图




图 2：单细胞高维向量 ANN 检索系统状态图

本状态图详细描述了系统中“ANN 索引对象”从创建、构建、持久化到最终删除的完整生命周期。通过状态的流转，展示了系统如何处理大规模单细胞向量数据的准备工作以及对异常情况（如构建失败或数据变更）的响应机制。

核心状态定义

1. **未创建 (Uninitialized)**: 系统的初始起点, 表示此时尚未进行任何数据导入或索引操作。
2. **数据已导入 (Data Imported)**: 表示原始的单细胞表达矩阵文件 (如 `.h5ad` 或 `.csv`) 已成功上传至服务器, 等待后续处理。
3. **预处理中 (Preprocessing)**: 这是一个中间过渡状态。系统正在对原始数据进行清洗、归一化以及高维特征向量的提取与组织。
4. **索引构建中 (Indexing)**: 系统正在利用底层算法 (如 Faiss、HNSW) 构建近似最近邻搜索结构。这是计算密集型阶段。
5. **可用 (Available)**: 索引构建成功并驻留在内存中, 系统此时已具备执行高效检索的能力。
6. **已保存 (Saved)**: 索引已成功写入物理磁盘 (持久化存储), 即使系统重启, 也可直接加载而无需重新构建。
7. **已加载 (Loaded)**: 从磁盘读取已有的索引库并加载到内存后的状态。
8. **查询中 (Searching)**: 检索动作正在执行时的临时状态。
9. **失效/需重建 (Invalid/Rebuilding)**: 当底层数据发生更新或参数 (如维度、距离度量) 改变时, 旧索引进入该状态。
10. **已删除 (Deleted)**: 流程的终点, 索引文件及内存占用被彻底清除。

状态流转逻辑说明

1. 准备与构建阶段 (正向主流程):

- 系统从“未创建”开始, 通过执行“导入数据”动作进入**数据已导入**状态。
- 随后, 系统自动启动“开始预处理”, 状态转为**预处理中**, 并在完成后进入**索引构建中**。
- 若“构建成功”, 索引状态转为**可用**。

2. 持久化与复用流程:

- 处于**可用**状态的索引可以通过执行“保存索引”动作, 转为磁盘上的**已保存**状态。
- 当系统需要再次使用该索引时, 通过“加载索引”动作, 状态变为**已加载**。此时, 索引重新回到内存活跃状态。

3. 业务执行流程:

- 处于**可用**或**已加载**状态的索引, 在接收到用户请求时会进入**查询中**。一旦“查询完成”, 状态会自动回滚到原有的活跃状态, 以便响应下一次请求。

4. 维护与失效机制:

- **异常处理**: 在“索引构建中”若发生“构建失败”, 系统会直接转入**失效/需重建**状态。
- **数据同步**: 即使索引处于“可用”、“已加载”或“已保存”状态, 只要发生“数据更新”或“参数变更”, 系统都会通过相应的触发路径强制将状态转为**失效/需重建**, 随后通过“重新构建”回到起始的预处理阶段。

5. 资源释放:

- 在“可用”、“已加载”或“已保存”状态下, 用户或管理员均可执行“删除索引”指令, 使索引进入**已删除**状态, 释放系统资源。

组件图




图 7：单细胞高维向量 ANN 检索系统组件图

本构件图展示了“单细胞高维向量 ANN 检索系统”的模块化物理结构。系统采用高内聚、低耦合的设计原则，将功能划分为表现层构件、业务逻辑层构件以及持久化支撑构件，确保了系统的可扩展性与易维护性。

核心构件及其职能

1. 表现层构件 (UI Layer):

- **Web 前端**：系统的唯一外部交互入口，作为边界构件，它依赖于后端所有业务功能模块，负责收集用户参数并呈现最终视图。

2. 业务处理与逻辑构件 (Logic Layer):

- **用户认证组件**：负责身份验证与权限控制。Web前端 通过 `<<depends>>` 关系依赖此组件，确保检索操作的安全性。
- **数据管理组件**：系统的核心调度中枢。它不仅协调 预处理组件 的工作，还与 查询检索模块 存在紧密的依赖关系。
- **预处理组件**：专门负责原始单细胞数据的解析、标准化及向量化。
- **查询检索模块**：执行 ANN 核心算法的逻辑单位。它依赖于 索引构建组件 提供的检索能力，并向可视化组件交换数据。
- **可视化展示组件 & 详情组件**：负责检索结果的后期处理，通过 `<<exchange>>` 关系与检索模块进行数据交换，生成降维图表和细胞属性详情。

3. 索引与存储构件 (Storage & Index Layer):

- **索引构建组件**：封装了底层 ANN 算法（如 Faiss, HNSW），负责将高维向量转化为可搜索的数学结构。
- **索引管理组件**：负责索引的生命周期管理，通过 `<<interact>>` 关系与构建组件协同工作，确保索引的正确加载与内存驻留。

4. 横向支撑构件 (Support Layer):

- **日志与监控组件**：负责全系统的运行跟踪。它通过 `<<monitor>>` 关系实时监控 查询检索模块 和 索引管理模块 的运行效率（如检索延迟、内存占用等）。

构件间的依赖与交互关系说明

图中的连接线揭示了数据在构件间的物理流动路径：

- 1. 数据的输入与获取 (Input Flow):
 - 数据管理组件 通过 <<invoke>> 消息触发 预处理组件。
 - 预处理组件 通过 <<use>> 关系读取外部的单细胞数据集（如 .h5ad 或 .csv 文件）。
- 2. 索引的生产与持久化 (Index Flow):
 - 索引构建组件 在完成计算后，通过 <<output>> 关系将物理索引库写入文件存储/索引文件中。
 - 索引管理模块 通过 <<support>> 关系从存储节点加载索引供检索模块使用。
- 3. 结果的加工与呈现 (Output Flow):
 - 查询检索模块 在得到原始 Top-k 结果后，通过数据交换关系（<<exchange>>）将数据传递给 可视化展示组件 进行 UMAP 渲染，并传给 详情组件 查询元数据。
 - 所有这些结果构件最终回流至 Web前端 完成响应。

设计亮点总结

- 解耦设计：通过引入独立的 索引管理组件，将复杂的索引加载逻辑与核心查询算法解耦，使得更换底层搜索算法（如从 Faiss 切换到 ScaNN）而无需重构前端逻辑。
- 监控集成：独立的 日志与监控组件 与检索核心直接相连，体现了系统对高性能 ANN 检索指标（如 QPS 和召回率）实时监控的设计要求。

部署图




图 8：单细胞高维向量 ANN 检索系统部署图

本部署图展示了“单细胞高维向量 ANN 检索系统”的四层物理架构。为了应对单细胞高维向量数据检索时的高计算量与高内存需求，系统采用了**分布式部署策略**，将表现层、业务逻辑层、计算核心与存储层进行物理隔离，以确保系统的高可用性与扩展性。

节点（Node）职能划分

1. 客户端浏览器 (Client Browser Node):

- **环境:** 用户个人电脑或工作站的 Web 浏览器。
- **部署内容:** 运行系统的前端页面构件。
- **职责:** 负责 UI 渲染、用户输入采集及检索结果的可视化呈现。

2. Web 应用服务器 (Web Application Server Node):

- **环境:** 部署在云端或实验室服务器的 Web 容器环境 (如 Nginx/Gunicorn) 。
- **部署内容:** 包含 **Web 后端服务**、**认证服务**以及**系统控制后端 API**。
- **职责:** 作为系统的网关, 负责处理用户请求、执行身份验证与权限校验, 并将业务逻辑分发给后端的计算集群。

3. 计算 / 检索服务器 (Computing & Retrieval Server Node):

- **环境:** 高性能计算节点, 配置有大容量内存和多核 CPU (或 GPU 加速器) 。
- **部署内容:** 核心构件包括**数据管理与处理服务**、**索引构建与加载服务**、**ANN 检索服务**及**评测服务**。
- **职责:** 承担系统最重的计算压力, 包括单细胞数据的向量化、ANN 索引的即时构建、高维空间近邻搜索以及性能指标的实时计算。

4. 数据库与存储服务器 (Database & Storage Server Node):

- **环境:** 专用数据服务器或分布式存储集群。
- **部署内容:** 包含四类核心制品 (Artifacts): **用户数据库**、**单细胞数据集**、**索引文件库**及**日志文件**。
- **职责:** 负责系统所有静态资源与动态数据的持久化存储。

通信路径与交互协议

图中的连接线详细定义了各物理节点间的协作协议:

- 客户端与 Web 端的交互:** 采用标准的 **HTTP/HTTPS** 协议, 确保数据传输的安全性和 Web 端的通用性。
- Web 服务器与计算集群的交互:** 采用 **REST/gRPC** 协议。考虑到单细胞高维向量数据量巨大, 使用 gRPC 可以提供更高效的序列化和更低的调用延迟, 适合向量数据的频繁传输。
- 计算节点与存储节点的交互:**
 - 对于用户信息, 通过 **SQL** 语言访问结构化数据库。
 - 对于 `.h5ad` 数据集和 `.index` 索引文件, 通过高速 **文件 I/O (File I/O)** 方式读取, 以满足大规模数据加载的性能要求。

系统部署特色总结

- **计算与存储分离:** 这种架构允许根据数据量的增长单独扩容存储服务器, 或根据检索并发量的提升单独增加计算服务器, 体现了良好的弹性。
- **安全性设计:** 认证服务部署在 Web 应用层, 作为一道防线拦截非法请求, 保护后端的计算资源和敏感的数据集制品不被非法访问。
- **高性能支撑:** 将 ANN 检索服务独立部署在高性能计算节点, 能够最大限度地利用硬件性能缩短检索响应时间 (Latency), 并提升每秒查询数 (QPS) 。